

- Informe Técnico: Modelado, Evaluación y Despliegue (Fases 4-6 CRISP-DM)
 - 1. Fase: Modelamiento (Modeling)
 - 1.1. Estrategia de Validación
 - 1.2. Selección de Algoritmos
 - 2. Fase: Evaluación (Evaluation)
 - 2.1. Métricas de Evaluación
 - 2.2. Resultados y Comparación de Modelos
 - 2.3. Análisis Crítico del Ajuste Perfecto () y Segunda Iteración
 - 3. Fase: Despliegue (Deployment)

Informe Técnico: Modelado, Evaluación y Despliegue (Fases 4-6 CRISP-DM)

Autor: Héctor Aguila

Proyecto: Predicción de Desempeño en eSports

Metodología: CRISP-DM

1. Fase: Modelamiento (Modeling)

1.1. Estrategia de Validación

Se empleó una partición estándar de datos:

- **Train/Test Split:** 80% de los datos para entrenamiento y 20% para evaluación externa.
- **Reproducibilidad:** Se fijó una semilla aleatoria (`random_state = 42`) para asegurar consistencia en las comparaciones de los modelos.

1.2. Selección de Algoritmos

Se seleccionaron tres alternativas de modelos con diferentes arquitecturas para evaluar su comportamiento frente a los datos:

- Regresión Lineal (Baseline):** Modelo fundamental para capturar relaciones lineales y proveer máxima interpretabilidad en la ponderación de coeficientes.
- Regresión Ridge (Regularización L2):** Variante lineal que introduce una penalización sobre los coeficientes grandes para prevenir el sobreajuste y mitigar problemas de multicolinealidad.
- Árbol de Decisión Regresor (No Lineal):** Algoritmo no paramétrico que divide el espacio de características en regiones ortogonales, útil para capturar interacciones no lineales complejas sin necesidad de escalamiento de datos.

2. Fase: Evaluación (Evaluation)

2.1. Métricas de Evaluación

Para comparar la precisión y generalización de los modelos, se calcularon las siguientes métricas estadísticas en los conjuntos de entrenamiento y prueba:

- Coeficiente de Determinación (R^2):** Proporción de la varianza del target explicada por el modelo.
- Error Absoluto Medio (MAE):** Promedio de las diferencias absolutas entre las predicciones y los valores reales.
- Error Cuadrático Medio (MSE) y su Raíz (RMSE):** Penaliza los errores de mayor magnitud, midiendo la desviación estándar de los residuos.

2.2. Resultados y Comparación de Modelos

Modelo	R^2 (Train)	R^2 (Test)	MAE (Test)	RMSE (Test)	Generalización
Regresión Lineal	1.0000	1.0000	0.0000	0.0000	Excelente (Ajuste Perfecto)
Regresión Ridge	1.0000	1.0000	0.0001	0.0001	Excelente (Ajuste Perfecto)
Árbol de Decisión	1.0000	0.9412	2.5120	3.1245	Sobreajuste leve (Típico de árboles)

2.3. Análisis Crítico del Ajuste Perfecto ($R^2 = 1.0000$) y Segunda Iteración

Obtener un error de cero absoluto ($MAE = 0.00$ y $R^2 = 1.0000$) en datos de rendimiento humano es una anomalía estadística severa. Un factor clave que despertó sospechas fue que, durante la fase de depuración y limpieza de outliers (tanto por el filtro biológico de 120 ms como por el método IQR), **solo se eliminaron 8 registros en total**, entrenando con el 98.4% del dataset original.

Con casi todo el dataset intacto y sin ruido típico de la conducta humana, un ajuste perfecto indicaba una de dos opciones: *Target Leakage* (fuga de información) o un dataset sintético determinista. Esto motivó una segunda iteración de CRISP-DM para auditar el flujo:

1. **Auditoría:** Se identificaron las variables de resultado de partida (`win_probability` y `mvp_award`) como posibles variables filtradoras del target.
2. **Prueba:** Se reentrenaron los modelos excluyendo estas variables del conjunto de entrenamiento.
3. **Resultado:** Los modelos lineales (Regresión Lineal y Ridge) **siguieron obteniendo un $R^2 = 1.0000$ perfecto**.
4. **Conclusión Científica:** Se demostró matemáticamente que el dataset es **100% sintético y determinista lineal**. La variable objetivo `performance_score` se calcula mediante una combinación lineal exacta de los atributos del jugador sin un término de error aleatorio ($\epsilon = 0$). Los algoritmos lineales descubren esta fórmula exacta, mientras que el Árbol de Decisión obtiene un R^2 menor debido a que aproxima una función continua mediante escalones.

Decisión del Mejor Modelo: Se seleccionó **Regresión Lineal** (o Ridge con regularización despreciable) por su capacidad de reproducir de manera exacta la función generadora de datos con costo computacional mínimo.

3. Fase: Despliegue (Deployment)

Para dar valor práctico al modelo desarrollado y permitir simulaciones interactivas por parte del cuerpo técnico de eSports, se implementaron dos niveles de despliegue:

- **Despliegue Interno (Jupyter):** Un formulario dinámico construido en el notebook mediante `ipywidgets` que permite cambiar parámetros de juego y observar la predicción del modelo de forma instantánea.
- **Despliegue Externo (Web App):** Una aplicación independiente en **Streamlit** (`[app.py]`
(file:///home/hector/Escritorio/FundamentosML/02_Modelado_Regresion/app.py)) que carga el pipeline serializado en `[best_model.joblib]`
(file:///home/hector/Escritorio/FundamentosML/02_Modelado_Regresion/best_model.joblib). Esta interfaz limpia y amigable permite simular escenarios de rendimiento de jugadores competitivos en tiempo real fuera de cualquier entorno de código.