

- Informe Técnico: Modelado, Evaluación y Despliegue - Clasificación (Fases 4-6 CRISP-DM)
 - 1. Fase: Modelamiento (Modeling)
 - 1.1. Estrategia de Validación y Mitigación de Data Leakage
 - 1.2. Selección de Variables Predictoras y Target
 - 1.3. Auditoría del Dataset y Decisión de Ingeniería de Cambio de Target
 - 1.4. Selección de Algoritmos
 - 2. Fase: Evaluación (Evaluation)
 - 2.1. Resultados del Rendimiento por Modelo (Test Set)
 - 2.2. Análisis Crítico y Evidencia de la Caída de KNN
 - 3. Fase: Despliegue (Deployment)
 - 4. Declaración de Uso de IA Generativa

Informe Técnico: Modelado, Evaluación y Despliegue - Clasificación (Fases 4-6 CRISP-DM)

Autor: Héctor Aguila **Asignatura:** Fundamentos de Machine Learning **Metodología:** CRISP-DM

1. Fase: Modelamiento (Modeling)

1.1. Estrategia de Validación y Mitigación de Data Leakage

Para garantizar la validez científica del experimento y prevenir activamente el **Data Leakage** (fuga de datos) que infla artificialmente el rendimiento, se adoptaron las siguientes directrices estructurales:

- **División Temprana (Train/Test Split):** La separación de los datos en 80% para entrenamiento (2233 registros) y 20% para prueba (559 registros) se realizó **antes de aplicar cualquier transformación**. Esto evita que los estadísticos globales del dataset (media y desviación estándar) se filtren en la fase de ajuste del modelo.

- **Semilla y Estratificación:** Se fijó una semilla aleatoria (`random_state=42`) para garantizar la reproducibilidad y se estratificó la partición para preservar el balance original de clases (Jugadores MVP y No MVP).
- **Encapsulamiento en Pipelines:** El preprocesamiento de datos (estandarización con `StandardScaler` de numéricas y codificación con `OneHotEncoder` de categóricas) se integró en `Pipelines` independientes para cada algoritmo. Esto asegura que la estandarización aprenda los parámetros (`fit`) únicamente del conjunto de entrenamiento y los aplique de forma aislada al test set.

1.2. Selección de Variables Predictoras y Target

- **Target Categórico:** `mvp_award` mapeado a binario (1 para MVP/Yes, 0 para No MVP/No).
- **Variables Predictoras (Features):** Se descartaron identificadores sin valor predictivo (`record_id`, `player_id`). Se conservaron variables físicas y estadísticas, e incorporamos `match_outcome` (Win/Loss) como variable predictora categórica (ya que al final de la partida el resultado sí influye de manera natural en la asignación del MVP).
- **Traspaso de Target a Feature:** La variable `performance_score` (que en la entrega anterior funcionaba como target de regresión) se incorporó en esta fase como una variable predictora clave.

1.3. Auditoría del Dataset y Decisión de Ingeniería de Cambio de Target

Durante la fase de *Data Understanding*, se auditó la distribución de la variable objetivo inicial `match_outcome` (Victoria/Derrota), revelando un desbalanceo extremo: **2793 victorias vs. solo 7 derrotas**. Con un desbalanceo del 99.75%, cualquier clasificador predice siempre la clase mayoritaria "Win" y obtiene una exactitud perfecta sin aprender nada, lo que invalida el experimento.

Por consiguiente, se tomó la decisión metodológica de usar `mvp_award` como target de clasificación. Cuenta con una distribución realista de **2561 registros "No" vs. 239 registros "Yes"** (un balance aproximado del 90%/10%), lo que expone a los modelos a

una clasificación binaria real donde el rendimiento y las distancias se pueden evaluar empíricamente.

1.4. Selección de Algoritmos

Se entrenaron tres algoritmos de clasificación de distintas características y geometrías:

- 1. Regresión Logística:** Clasificador lineal clásico probabilístico.
- 2. K-Nearest Neighbors (KNN):** Algoritmo no paramétrico basado en distancias espaciales locales.
- 3. Random Forest Classifier:** Ensamble no lineal (Bagging) de árboles de decisión no correlacionados.

2. Fase: Evaluación (Evaluation)

2.1. Resultados del Rendimiento por Modelo (Test Set)

El rendimiento de los clasificadores en el conjunto de prueba para predecir la clase positiva **MVP (1)** se detalla a continuación:

Modelo	Accuracy	Precision (MVP)	Recall (MVP)	F1-Score (MVP)	ROC AUC
Regresión Logística	0.9946	0.9592	0.9792	0.9691	0.9980
K-Nearest Neighbors (K=5)	0.9517	0.8621	0.5208	0.6494	0.9995
Random Forest Classifier	1.0000	1.0000	1.0000	1.0000	1.0000

2.2. Análisis Crítico y Evidencia de la Caída de KNN

- **La Debilidad Empírica de KNN:** En las matrices de confusión y reportes del notebook se evidencia la caída en el rendimiento de KNN. Su exactitud global baja a 95.17%, pero lo más crítico es el **F1-Score para la clase MVP, que cae a 0.6494** con un recall de solo 52.08% (dejando de identificar casi a la mitad de los jugadores MVP reales). Esto demuestra geométricamente la sensibilidad de KNN al desbalance de clases y a la dimensionalidad en el espacio de características.
- **Separación Perfecta de Random Forest:** El Random Forest Classifier alcanza métricas perfectas en test (1.0000), confirmando que el algoritmo basado en árboles descorrelacionados con cortes ortogonales logra replicar de manera exacta las fronteras de decisión de este dataset sintético lineal.

Selección del Modelo Campeón: Se selecciona **Random Forest Classifier** por su excelente rendimiento general y se guarda en checkpoints.

3. Fase: Despliegue (Deployment)

- **Pipeline Serializado:** Se importó el pipeline del clasificador desde el archivo serializado [`best_model.joblib`] (`file:///Users/user/Desktop/FundamentosML/03_Modelos_Clasificacion/checkpoints/best_model.joblib`), garantizando que las transformaciones se apliquen de forma transparente en producción.
 - **Interfaz de Inferencia:** Se diseñó una aplicación en Streamlit (`app.py`) en modo oscuro. Ofrece selectores para variables categóricas (Equipo, Rol, Mapa, Tipo de partida y el resultado `match_outcome`) y sliders para las numéricas.
 - **Inferencia Instantánea:** Al presionar "Predecir MVP", el sistema calcula la predicción en tiempo real y renderiza tarjetas personalizadas: un banner verde brillante con **JUGADOR MVP (Yes)** o uno estándar con **JUGADOR ESTÁNDAR (No)**.
-

4. Declaración de Uso de IA Generativa

De acuerdo con el compromiso de honestidad académica y las políticas de Duoc UC:

- **Uso del Asistente como Andamio de Aprendizaje:** Se declara el uso de IA generativa como un andamio cognitivo y técnico para el desarrollo de esta entrega.

Las decisiones críticas del flujo experimental —como el diagnóstico del desbalanceo masivo en **match_outcome** y la re-orientación del target hacia **mvp_award**, junto con la arquitectura de los pipelines de preprocesamiento aislado para mitigar el data leakage— fueron debatidas, guiadas y estructuradas de forma conjunta con el asistente.

- **Soporte Técnico:** Adicionalmente, se utilizó la herramienta para el formateo del markdown del informe, la optimización del código del gráfico doble de subplots (curvas ROC/PR) y el diseño estético de la interfaz Streamlit en Python.